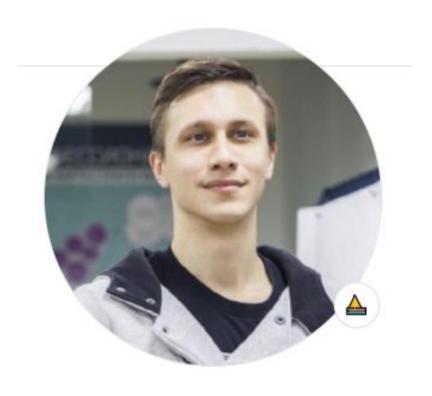


# РЕКОМЕНДАТЕЛЬНЫ Е СИСТЕМЫ НА ПРАКТИКЕ

СЕЛЕЗНЕВ АРТЕМ



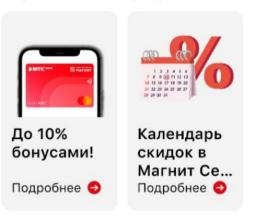
- @SeleznevArtem
- in /seleznev-artem
- NameArtem

### **CVM**

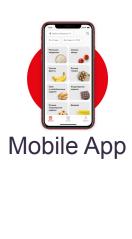


### Только для вас

#### Персональные предложения













> 60 млн. человек







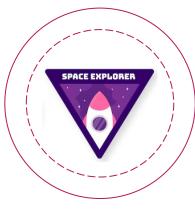
Массовое промо

Рекомендации









**День 1** Основы рекомендаций

Постановка задачи

Базовые алгоритмы



**День 2** Бустинги и рекомендации

Задачи ранжирования

Валидация и метрики



Запуск соревнования Kaggle

Боремся за метрику



**День 3** Проблемы в рекомендациях

Больше факторов



#### Финальный проект

Создать готовое решение

Проект проходи «продуктовую» приёмку



Popularity-Based Jokes Recommendation

Detail Compact	Column	
About this file List of jokes		
▲ 1: A man visits th =	▲ I have bad news f =	▲ Well, thank God I =
142 unique values	[null] 22% "Ah 1% Other (109) 77%	[null] 30% "No 1% Other (98) 69%
2: This couple had an excellent relationship going until one day he came home from work to find his	"That's an awfully big word for a ten year old."	
3: Q. What's 200 feet long and has 4 teeth? A. The front row at a Willie Nelson concert.		
4: Q. What's the difference between a man and a toilet? A. A toilet doesn't follow you around after		



$$RMSE = \sqrt{\frac{\displaystyle\sum_{i=1}^{N} \left(Predicted_i - Actual_i\right)^2}{N}}$$
 ———— Лучший результат



Финальный проект

Создать готовое решение

Проект проходи «продуктовую» приёмку

$$MAP@k = rac{1}{|Users|} \sum_{u \in Users} AP@k(u)$$

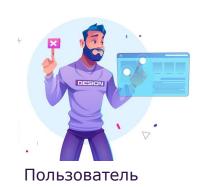
#### Проверка по RMQ:

- Соответствие гипотезе
- Финансовая оценка на A/B тесте с BaseLine
- Обработка не популярных предметов (покрытие рекомендациям)
- Средняя частота взаимных совпадений (ARHR)
- Новизна
- Интуитивность (Serendipity)





Владелец продукта









Владелец продукта

Пользователь





Я создаю гипотезы

#### Я работаю с метриками и очень data-driven



Владелец продукта



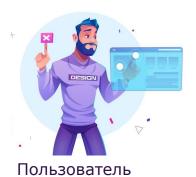
Владелец продукта

Пользователь





Меня окружает мир рекомендаций Является ли это моим настоящим выбором?







Владелец продукта

Пользователь



DESIGN I

Senior



Senior

Я всё могу?



# РЕКОМЕНДАЦИИ ВЕЗДЕ



Ваши первые рекомендации



Первые безответственные рекомендации



Что-то было не рекомендацией



# РЕКОМЕНДАЦИИ ВЕЗДЕ



Ваши первые рекомендации



Первые безответственные рекомендации



Таргетировано, но ещё не рекомендации



# РЕКОМЕНДАЦИИ ВЕЗДЕ



Ваши первые рекомендации



Первые безответственные рекомендации



ВАЛЛ-И плохое будущее



## МЫ В ОТВЕТЕ ЗА ТЕХ, КОМУ ПОРЕКОМЕНДОВАЛИ



# МЫ В ОТВЕТЕ ЗА ТЕХ, КОМУ ПОРЕКОМЕНДОВАЛИ

Что это означает? Они будут не самые <del>релевантные</del> подходящие?



Мы должны знать больше о покупателях...



# ЗНАНИЯ ДО РЕКОМЕНДАЦИЙ

Жизненный цикл клиента в системе



# ЗНАНИЯ ДО РЕКОМЕНДАЦИЙ

Жизненный цикл клиента в системе



#### Миссии клиента в системе

	Жанр / Время			
UID	Комедии	Ужасы	Спорт	Мультфильмы
1	0	1 / 93	5 / 500	0
2	4 / 374	2 / 180	0	6 / 540
3	9 / 810		0	45 / 1050

UID	Миссия	
1	Просмотр футбола	
2	Семейный	
3	Мультики в обеденный перерыв	

# Это называется продвижение. Не зависимо от того, что мы используем лента должна «зарабатывать»

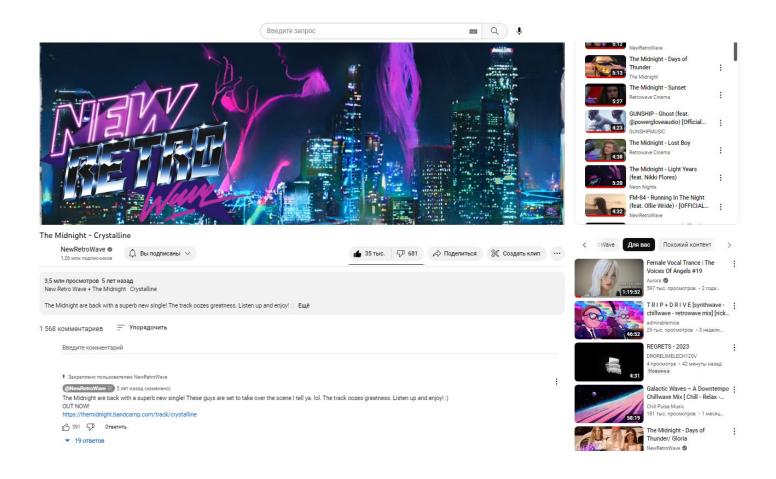


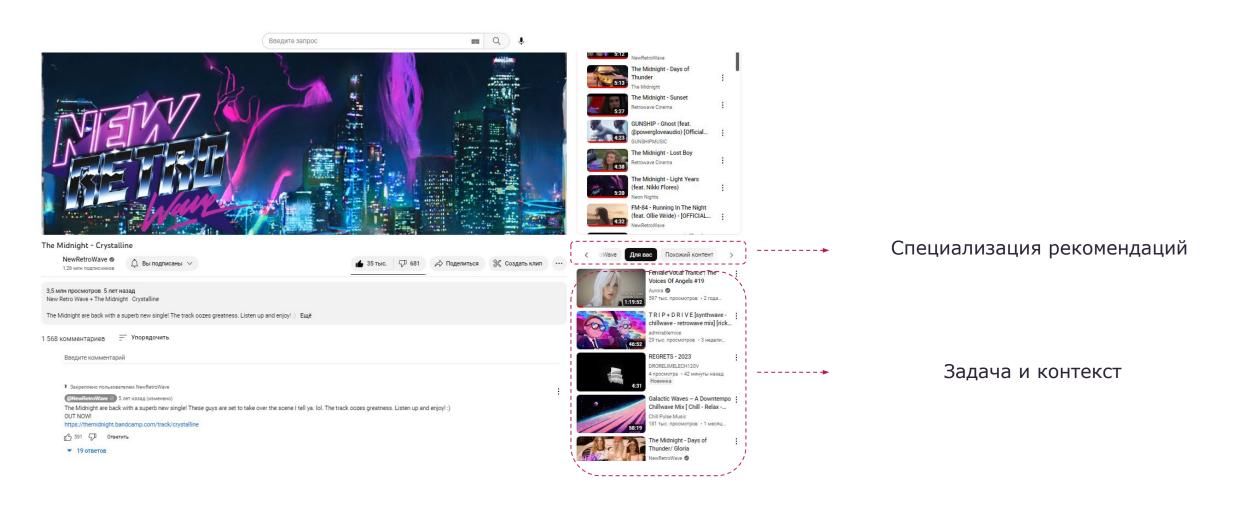
Но мне в ленту рекомендаций попадают фильмы или товары, которые я уже смотрел / купил.

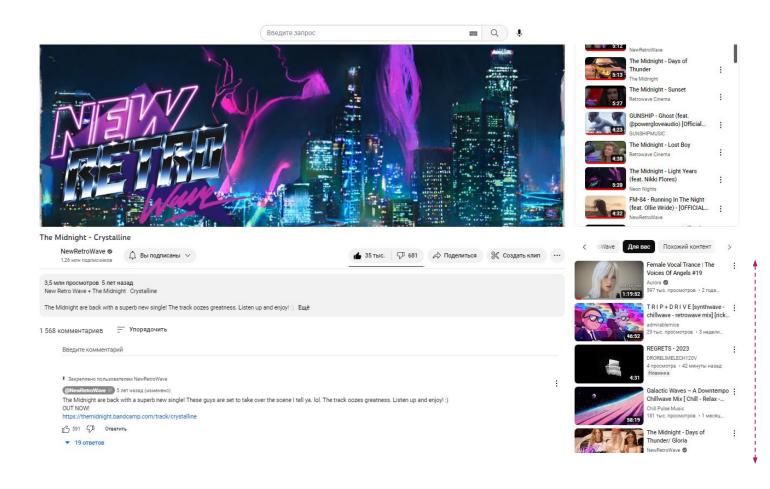


Но моя метрика...







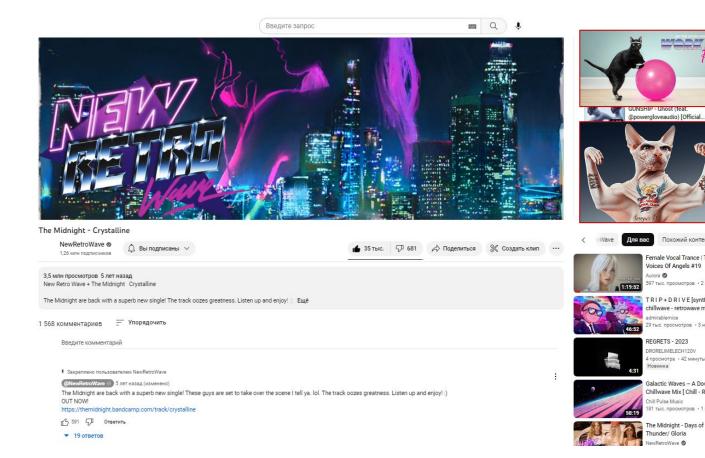


Размер персонализации

Персональные

Не персональные, но самый популярный

Контекст и интерфейс создают успех!



Релевантный контекст

Не релевантный контекст

Похожий контент

Female Vocal Trance | The Voices Of Angels #19

597 тыс. просмотров • 2 года...

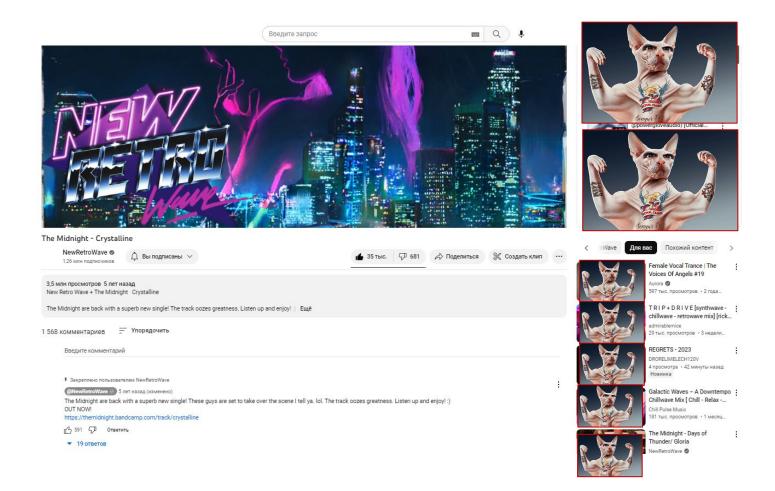
REGRETS - 2023 DRORELIMELECH120V просмотра • 42 минуты назад

Chill Pulse Music 181 тыс. просмотров • 1 месяц...

The Midnight - Days of

TRIP+DRIVE [synthwave chillwave - retrowave mix] [rick...

Galactic Waves - A Downtempo : Chillwave Mix [ Chill - Relax -...



#### Агрегатор рекламы Это уже не рекомендация



# ИНФОРМАЦИЯ О ПОЛЬЗОВАТЕЛЯХ

# У меня есть данные, но как на их основе строить рекомендации?



#### <del>Красная или синяя, Heo</del> CSR или CSC матрица



				кол-во	кол-во		
UID	пол	возраст	регион	скроринга	просмотров	рекомендация	рейтинг
1	M	23	M	0,11	1	43	3
2	Ж	25	M	0,43	2	11	4
3	Ж	18	С	0,95	1	7	1

UID	43	11	7
1	3	?	?
2	?	4	?
3	?	?	1

UID	IID	Rating
1	43	3
2	11	4
3	7	1

#### Compressed Sparse Column Matrix

UID	43	11	7
1	3	?	?
2	?	4	?
3	?	?	1

Кумулята не 0 в столбце: 0, 1, 2

Строка: 0, 1, 2 Значение: 3, 4, 1 Размерность: 3х3

#### Compressed Sparse Row Matrix

UID	43	11	7
1	3	?	?
2	?	4	?
3	?	?	1

Кумулята не 0 в строке: 0, 1, 2

Стобец: 0, 1, 2 Значение: 3, 4, 1 Размерность: 3х3

#### Compressed Sparse Column Matrix

UID	43	11	7
1	3	?	?
2	?	?	?
3	?	4	1
			,

Кумулята не 0 в столбце: 0, 1, 2

Строка: 0, 0, 2 Значение: 3, 4, 1 Размерность: 3х3

Pointer CSC

0 1 2 3 4

Index Pointers

0 1 1 4 6 7

Indices

7 1 2

Data

Power Hoteland

Pointer

O 1 1 4 4 6 4

Data

O Data

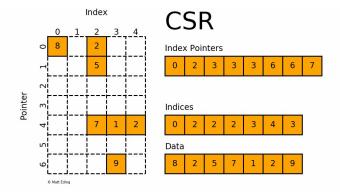
O Matt Eday

#### Compressed Sparse Row Matrix

UID	43	11	7
1	3	2	?.,
2	?	?	4
3	?	?	1

Кумулята не 0 в строке: 0, 1, 2

Столбец: 0, 0, 2 Значение: 3, 4, 1 Размерность: 3х3



Тип	Пустой вид
CSC	Matrix((M, N), dtype)
CSR	Matrix((M, N), dtype)
BSR	Matrix((M, N), blocksize = (R,C), dtype)
C00	Matrix((M, N), dtype)
DOK	Matrix((M, N), dtype)
LIL	Matrix((M, N), dtype)
DIA	Matrix((M, N), dtype)

### ИНФОРМАЦИЯ О ПОЛЬЗОВАТЕЛЕ

Так, а что мы там будем хранить? Мы же знаем о пользователе всё?



## ИНФОРМАЦИЯ О ПОЛЬЗОВАТЕЛЕ. АРХЕТИПЫ



#### Бесстрашный

Ужасы, триллеры, фанфик

Всегда смотрю самые жесткие фильмы, но не против фильмов на разные любительские тематики

В системе: 150 дней

Покупок: 21

#### Семейный, с особенностями

Комедии, детское, семейное

В основном включаю мультики ребенку, но иногда смотрю комедии 90x

В системе: 90 дней

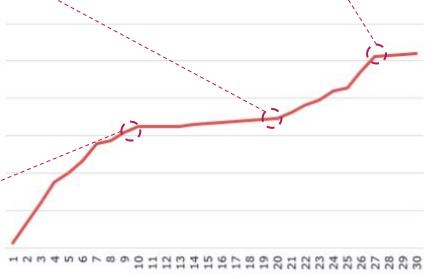
Покупок: 3

#### Успешный успех

Драмы, экшн, документальные

Смотрю фильмы на основе разных событий. Любою движуху.

В системе: 210 дней Покупок: 42



## ИНФОРМАЦИЯ О ПОЛЬЗОВАТЕЛЕ. АРХЕТИПЫ



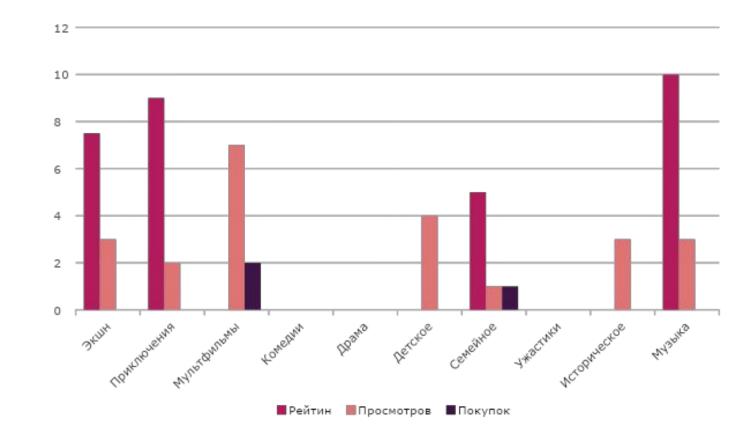
#### Семейный, с особенностями

Комедии, детское, семейное

В основном включаю мультики ребенку, но иногда смотрю комедии 90х

В системе: 90 дней

Покупок: 3



## ИНФОРМАЦИЯ О ПОЛЬЗОВАТЕЛЕ



#### Действие в системе

Просмотр объекта (задержка внимания)
Переход на объект
Добавление в корзину / отметка объекта
Покупка
Оценка / рейтинг
Рекомендация
Тайминг проведенный с объектом
Тайминг в системе
Оставленная корзина
Поисковые запросы в системе
Действия с объектом

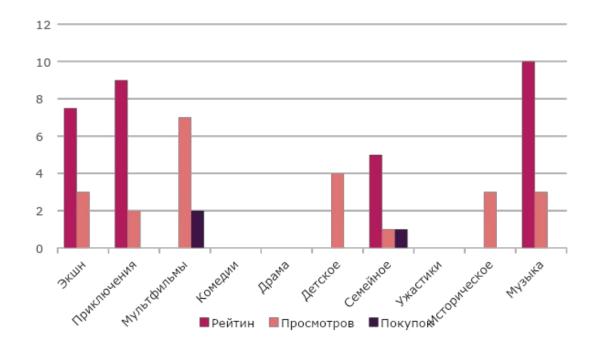
(чтение, перемотка, воспроизведение) Предложите выбор

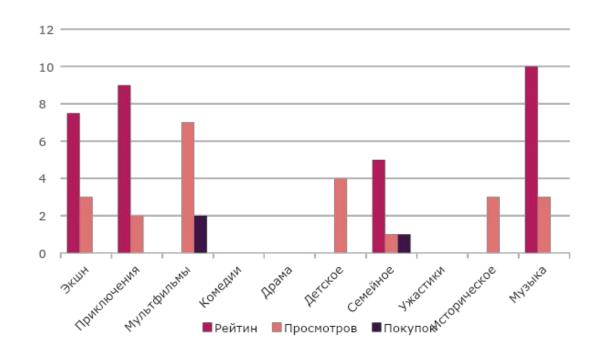
(корректировка по жанрам и т.д.)

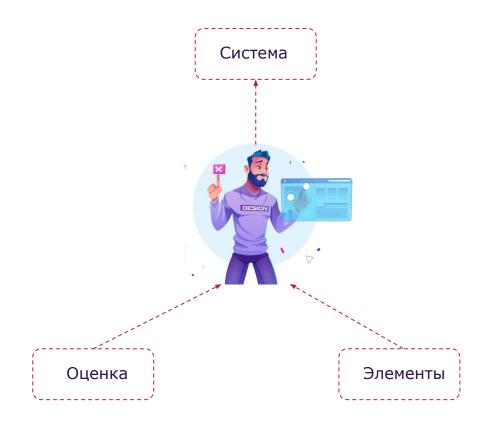
# ИНФОРМАЦИЯ О ПОЛЬЗОВАТЕЛЕ

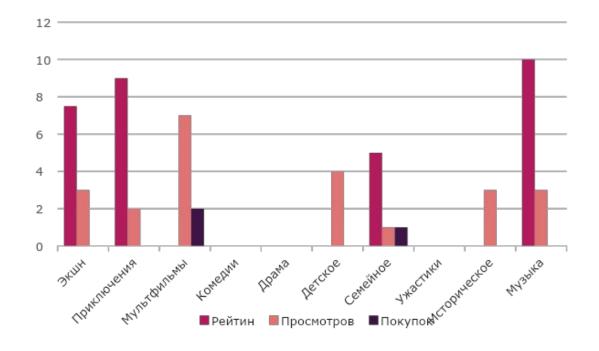


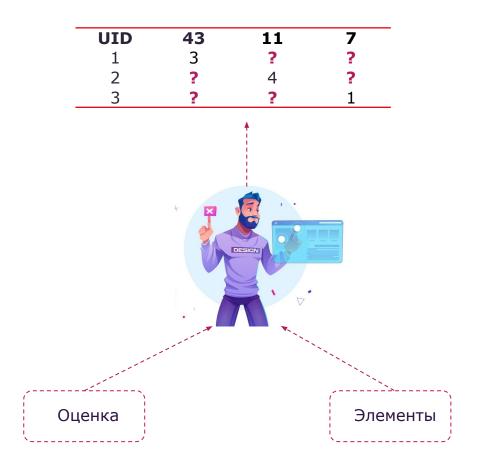
Фильтр Фильтр Фильтр Рекомендация Рекомендация Рекомендация Фильтр Фильтр
Фильтр Рекомендация Рекомендация Рекомендация Рекомендация Фильтр Фильтр
Рекомендация Рекомендация Рекомендация Фильтр Фильтр
Рекомендация Рекомендация Фильтр Фильтр
Рекомендация Фильтр Фильтр
Фильтр Фильтр
Фильтр
•
_
Фильтр
Рекомендация
Фильтр
Рекомендация

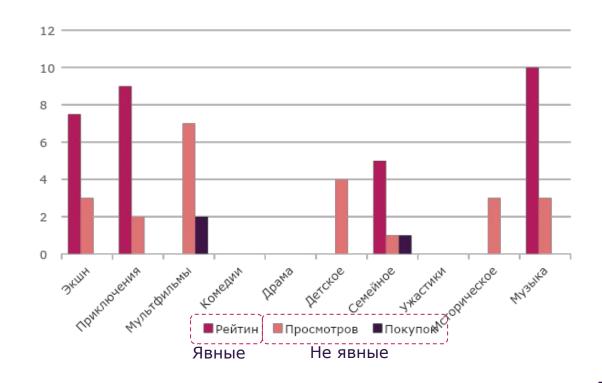














Выбираем тот тип данных, который дает больше информации



_				
	UID	43	11	7
	1	1	0	0
	2	0	1	0
	3	0	0	1

Купил или нет. Двоичная матрица. Черно-белая матрица =)

UID	43	11	7
1	10/N	0	0
2	0	77/N	0
3	0	0	3/N

Нормализованные на кол-во значения

UID	43	11	7
1	A1	0	0
2	0	A2	0
3	0	0	А3

Значение на основе функции:  $peйтинг - 1 / (a + 2)^b$ 

## ЧТО ЕСТЬ ОЦЕНКА (НЕ ЯВНАЯ ОЦЕНКА)



## Действие

Покупка Просмотр и долгая работа со страницей

Возвращение к просмотру

Один просмотр

#### Оценка

Высшая оценка

Хорошая оценка

Удовлетворительно

Плохо

IS = (w1\*coбытиe1) + ... + (wn\*coбытиen)

## ЧТО ЕСТЬ ОЦЕНКА (НЕ ЯВНАЯ ОЦЕНКА)



## Действие

Покупка Просмотр и долгая работа со страницей

Возвращение к просмотру

Один просмотр

#### Оценка

Высшая оценка

Хорошая оценка

Удовлетворительно

Плохо

$$IS = (w1*coбытиe1) + ... + (wn*coбытиen)$$

## ЧТО ЕСТЬ ОЦЕНКА. РЕДКИ ЭЛЕМЕНТЫ БОЛЕЕ ЦЕННЫ

У нас 1.000.000 аудитория, 100 оценок на элементе для нас не важны

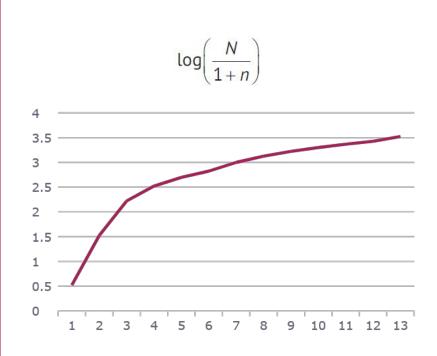


Это могут быть редкие элементы, которые очень значимы



# ЧТО ЕСТЬ ОЦЕНКА. РЕДКИ ЭЛЕМЕНТЫ БОЛЕЕ ЦЕННЫ





$$R_{i,u} \times \log\left(\frac{N}{1+n}\right)$$

R – рейтинг

N – кол-во пользователей

n - кол-во оценок элемента

### Наша система должна рекомендовать сразу. Нет времени ждать «знаний» о пользователе



Наверное, я решу это проблему как «холодный старт»



Но проще сделать не персональные...





# НЕ ПЕРСОНАЛЬНЫЕ РЕКОМЕНДАЦИИ

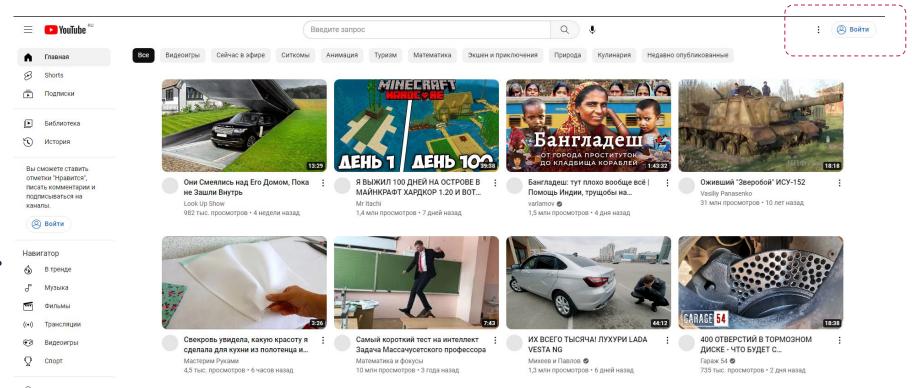
## НЕ ПЕРСОНАЛЬНЫЕ РЕКОМЕНДАЦИИ



- попытка убедить

#### Рекомендация

- то, что хочет пользователь



## НЕ ПЕРСОНАЛЬНЫЕ РЕКОМЕНДАЦИИ

#### Демонстрация контента:

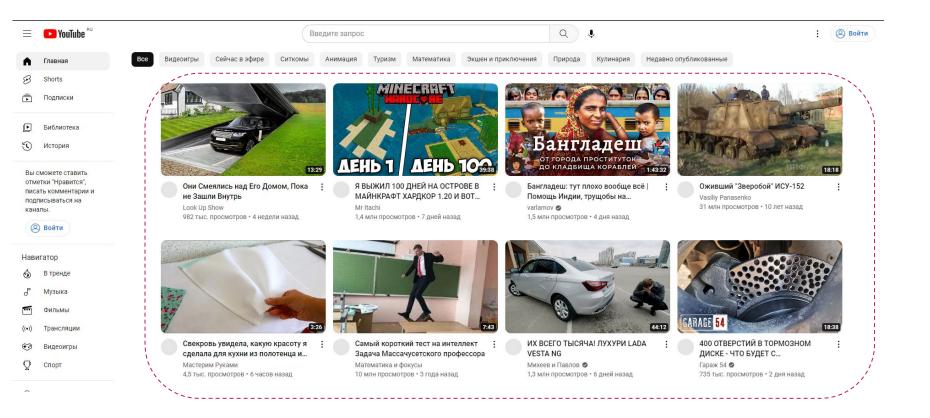
Топ N (по региону)

Среднее / медиана по рейтингу

«Выбор редакции»

Купили / посмотрели сегодня

Набор ассоциативных правил



## НЕ ПЕРСОНАЛЬНЫЕ РЕКОМЕНДАЦИИ

#### Демонстрация контента:

Топ N (по региону)

Среднее / медиана по рейтингу

«Выбор редакции»

Купили / посмотрели сегодня

Набор ассоциативных правил

### Рассмотрим на примере



# ВЕРНЕМСЯ К ТЕМЕ, КОГДА БУДЕМ РЕШАТЬ «ПРОБЛЕМЫ РЕКОМЕНДАЦИЙ»

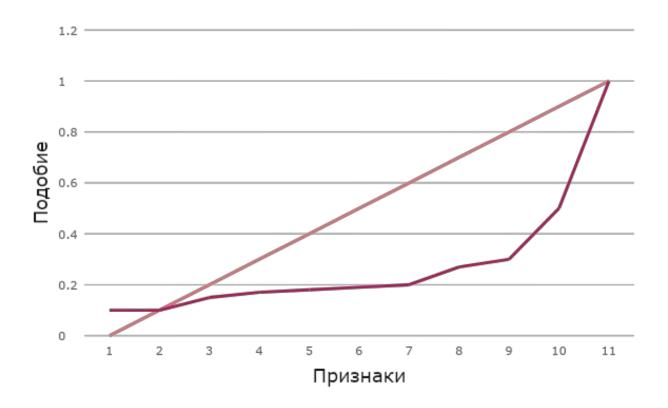


# ПРОСТЫЕ РЕКОМЕНДАЦИИ

А что такое, это ваше «сходство»?



SIM(i, j) = 1 - идентичны SIM(i, j) = 0 - не имеют общего



## Для разных данных, разное подобие

Тип	Пример	Подобие	
Количество (лайки, покупки)	Uid поставил лайк. Uid купил этот товар	Коэф. Жаккара	$cxoдcmвo_{_{\mathcal{M}akkapa}}ig(i,jig) = rac{\#noльзователи,\ купившие оба товара}{\#noльзователи, которые купили либо i ,либо$
Бинарные данные	UiD не понравился филы	и Коэф. Жаккара	
Количественные данные	UiD поставил 7/10 оценку	Коэф.Пирсона, Косинус, L-нормы	

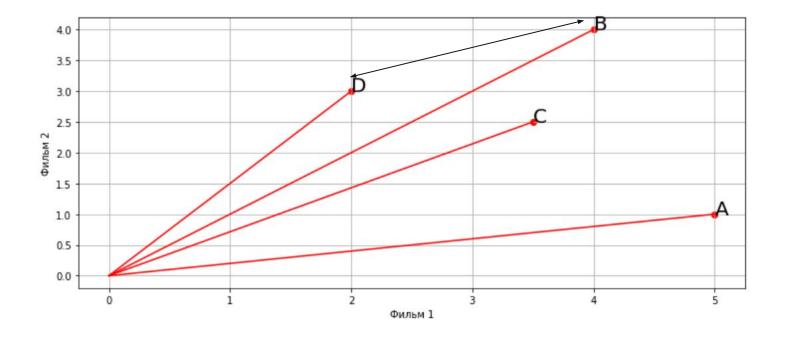
## Эвклидово расстояние (L2-norm)

$$d(x, y) = \sqrt{\sum_{i=1}^{k} (x_i - y_i)^2}$$



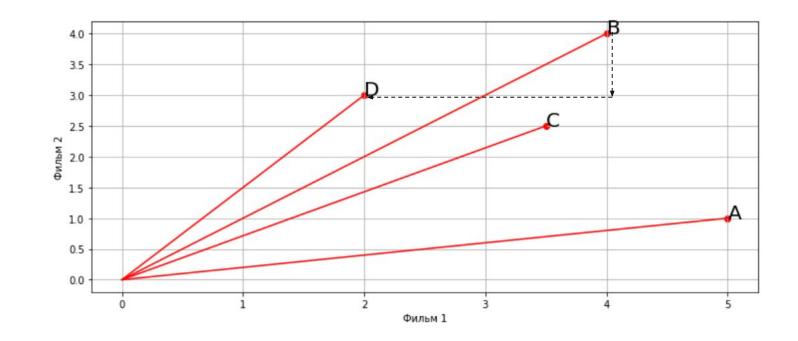
#### **RMSE**

RMSE = 
$$\sqrt{\frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y})^2}$$



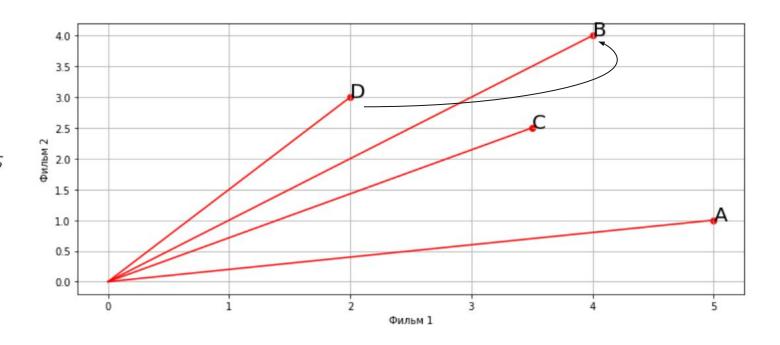
## Манхэттен (L1-norm)

$$|x1-x2|+|y1-y2||x1-x2|+|y1-y2|$$



#### Минковский

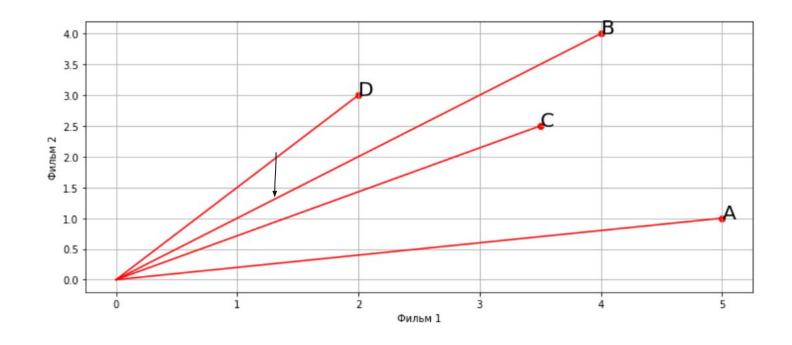
$$\sqrt[p]{(x1-y1)^p \ + \ (x2-y2)^p \ + \ \dots \ + \ (xN-yN)^p}$$



## Косинусное (Отиаи)

Cosine Similarity (A,B) = 
$$cos(\theta) = \frac{A.B}{\|A\| \|B\|} = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2} \sqrt{\sum_{i=1}^{n} B_i^2}}$$

$$K = rac{|A \cap B|}{\sqrt{|A| \cdot |B|}}$$



$$SIM(i, j) = 1$$
 - идентичны  $SIM(i, j) = 0$  - не имеют общего

## Рассмотрим на примере



## Хорошо, а в другой команде используют какието «фильтрации»

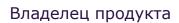


## Рассмотрим на примере



## ПРОГРАММА БУТКЭМПА (МАРКЕРЫ)













Я всё могу?

